

Capítulo 1

Estimação Pontual

1.1 Introdução

Inferência Estatística, ou "Aprendizado" como é chamado em Ciência da Computação, é o processo de buscar dados para inferir a distribuição que gera esses dados. Uma típica questão de Inferência Estatística é a seguinte:

Dado uma amostra $X_1, \dots, X_n \sim F$, como inferimos F ?

Em alguns casos, podemos querer inferir apenas algumas características de F , como sua média por exemplo.

Um **modelo estatístico** \mathcal{F} é um conjunto de distribuições (ou densidades ou funções de regressão).

Um **modelo paramétrico** é um conjunto \mathcal{F} que pode ser parametrizado por um número finito de parâmetros.

Por exemplo, se nós assumimos que os dados provêm de uma distribuição Normal, então o modelo é:

$$\mathcal{F} = \left\{ f(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\}, \mu \in \mathbb{R}, \sigma > 0 \right\}$$

Este é um modelo de dois parâmetros. Escrevemos a densidade como $f(x; \mu, \sigma)$ para mostrar que x é um valor da variável aleatória enquanto μ, σ são parâmetros.

Em geral, um modelo paramétrico assume a forma:

$$\mathcal{F} = \{f(x; \theta), \theta \in \Theta\}$$

onde θ é um parâmetro desconhecido (ou vetor de parâmetros) que pode levar valores no **espaço de parâmetros** Θ . Se θ é um vetor, mas estamos apenas interessados em um componente de θ , chamamos os parâmetros restantes de **parâmetros incômodos**.

Um **modelo não paramétrico** é um conjunto \mathcal{F} que não pode ser parametrizado por um número finito de parâmetros.

Estimadores e Estimativas Dado um parâmetro $\theta \in \Theta$ um *estimador* Muitos problemas inferenciais são resolvidos por meio de *Estimação, Intervalos de confiança e Testes de hipóteses*. Vamos tratar de todos esses problemas em detalhes.

Estimação Pontual Paramétrica ou Estimação Pontual é uma técnica que tenta fornecer uma única "melhor estimativa" de um parâmetro desconhecido.

Neste capítulo, vamos abordar a teoria sobre este assunto. Para resumir, usaremos o termo *estimativa* para se referir a uma única estimativa pontual.

1.2 A Ideia básica da Estimação Pontual

O problema aqui, resumidamente declarado, é o seguinte. Seja X um v.a. com um f.d.p. f que, no entanto, envolve um parâmetro. Este é o caso, por exemplo, na Distribuição binomial $B(1, p)$, a distribuição de Poisson $P(\lambda)$, a Exponencial negativa $f(x) = \lambda e^{-\lambda x}$, $x > 0$ a distribuição Uniforme $U(0, \alpha)$, e a distribuição normal $N(\mu, \sigma^2)$ com uma das quantidades μ e σ^2 conhecido. O parâmetro é geralmente denotado por θ , e o conjunto de seus valores possíveis, denotado por Θ é chamado de espaço de parâmetro. A fim de enfatizar o fato de que a f.d.p. depende de θ , escrevemos $f(\cdot; \theta)$. Assim, nas distribuições mencionadas acima, temos para as respectivos f.d.p.'s e os espaços de parâmetros:

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, x = 0, 1, \theta \in \Theta = (0, 1).$$

$$f(x; \theta) = e^{-\theta} \frac{\theta^x}{x!}, x = 0, 1, \dots, \theta \in \Theta = (0, \infty).$$

$$f(x; \theta) = \theta e^{-\theta x}, x > 0, \theta \in \Theta = (0, \infty).$$

$$f(x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta \\ \theta \in \Theta = (0, \infty) \\ 0 & \text{Caso contrário} \end{cases}$$

Distribuições normais são adequadas para modelar as situações descritas em Exemplos 16 e 17 do Capítulo 1.

Nosso objetivo é desenhar uma amostra aleatória de tamanho n , X_1, \dots, X_n , da distribuição subjacente e, com base nela, construir uma estimativa pontual (ou estimador) para θ , ou seja, uma estatística $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$, que é usada para estimar θ , onde uma estatística é uma função conhecida da amostra aleatória X_1, \dots, X_n . Se x_1, \dots, x_n são os valores realmente observados de v.a.'s X_1, \dots, X_n , respectivamente, então o valor observado de nossa estimativa tem o valor numérico $\hat{\theta}(x_1, \dots, x_n)$. Os valores observados x_1, \dots, x_n também são chamados de dados. Então, com base nos dados disponíveis, é declarado que o valor de θ é $\hat{\theta}(x_1, \dots, x_n)$ dentre todos os pontos possíveis em Θ . Uma estimativa pontual é muitas vezes referida apenas como uma estimativa, e a notação $\hat{\theta}$ é usada indiscriminadamente, tanto para a estimativa $\hat{\theta}(X_1, \dots, X_n)$ (que é um r.v.) e para seu valor observado $\hat{\theta}(x_1, \dots, x_n)$ (que é apenas um número).

A única restrição óbvia em $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ é que se encontra em Θ para todos valores possíveis de X_1, \dots, X_n . Além disso, há inúmeras estimativas pode-se construir portanto, a necessidade de assumir certos princípios e/ou inventar métodos para construir $\hat{\theta}$. Talvez, o princípio mais amplamente aceito seja o chamado princípio da Máxima Verossimilhança (MV). Este princípio dita que formamos a junta p.d.f. dos x_i 's, para os valores observados dos X_i 's, olhe para esta junta f.d.p. como uma função de θ (e chame-a de função de verossimilhança), e maximizar a função de verossimilhança em relação a θ . O ponto de maximização (assumindo que existe e é único) é uma função de (x_1, \dots, x_n) , e é o que nós chamamos de estimativa de máxima verossimilhança (MLE) de θ . A notação usada para a função de verossimilhança é $L(\theta|x_1, \dots, x_n)$. Então, temos isso:

$$L(\theta|x_1, \dots, x_n) = f(x_1; \theta) \dots f(x_n; \theta), \theta \in \Theta.$$

O MLE será estudado extensivamente no Capítulo 9.

Outro princípio frequentemente usado na construção de uma estimativa para θ é o princípio de imparcialidade. Neste contexto, uma estimativa geralmente é denotada por $U = U(X_1, \dots, X_n)$. Então, o princípio da imparcialidade dita que U deve ser construído de modo a ser imparcial; ou seja, sua expectativa (valor médio) deve ser sempre θ , não importa qual seja o valor de θ . Mais formalmente, $E_\theta U = \theta$ para todos $\theta \in \Theta$. (No sinal de expectativa E , o parâmetro θ foi inserido para indicar que esta expectativa depende de θ , uma vez que é calculada usando o f.d.p. $f(\cdot; \theta)$.) Agora, é intuitivamente claro que, ao comparar duas estimativas imparciais companheiros, um escolheria o outro com a pequena servidão, uma vez que seria mais fortemente concentrado em torno de sua média θ . Visualize o caso que, dentro da classe de todas as estimativas imparciais, existe uma que

tem a menor variância (e isso é verdade para todos os $\theta \in \Theta$). Essa estimativa é chamada de mínimo uniforme Estimativa de variância imparcial (UMVU) e é, claramente, uma estimativa desejável. Dentro No próximo capítulo, veremos como fazemos para construir essas estimativas.

O princípio (ou melhor, o método) baseado em momentos amostrais é outra forma de construir estimativas. O método dos momentos, no caso mais simples, dita para formar a média da amostra \bar{X} e igualá-la com a média (teórica) $E_{\theta}X$. Em seguida, resolva para θ (assumindo que pode ser feito, e, de fato, exclusivamente) na ordem para chegar a uma estimativa de momento de θ . Um método muito mais sofisticado de construção de estimativas de θ é o o chamado método teórico da decisão. Este método exige a introdução de uma série de conceitos, terminologia e notação, e será retomada na Próximo Capítulo.

Finalmente, outro método relativamente popular (em particular, no contexto de certos modelos) é o método dos mínimos quadrados (LS). O método de ligações LS para a construção de uma estimativa para θ , a Estimativa de Mínimos Quadrados (LSE) de θ , por meio de uma minimização (em relação a θ) da soma de certos quadrados. Esta soma dos quadrados representa os desvios quadrados entre o que realmente observar depois que a experimentação for concluída e o que esperaríamos ter com base em um modelo presumido. Mais uma vez, os detalhes serão apresentados mais tarde em, mais especificamente, no Capítulo 13.

Em toda a discussão anterior, foi assumido que o p.d.f. subjacente, dependia de um único parâmetro, denotado por θ . Pode muito bem ser caso haja dois ou mais parâmetros envolvidos. Isso pode acontecer, por exemplo, na distribuição uniforme $U(\alpha, \beta)$, $-\infty < \alpha < \beta < \infty$, onde ambos α e β são desconhecidos; a distribuição normal, $N(\mu, \sigma^2)$, onde ambos μ e σ^2 são desconhecidos; e isso acontece na distribuição Multinomial, onde o o número de parâmetros é k , p_1, \dots, p_k (ou mais precisamente, $k - 1$, uma vez que o k -ésimo parâmetro, por exemplo, $p_k = 1 - p_1 - \dots - p_{k-1}$). Por exemplo, Exemplos 20 e 21 do Capítulo 1 referem-se a situações em que uma distribuição Multinomial é apropriado. Em tais casos de multiparâmetros, simplesmente se aplica a cada parâmetro separadamente o que foi dito acima para um único parâmetro. A opção alternativa de usar a notação vetorial para os parâmetros envolvidos simplifica as coisas de certa forma, mas também introduz algumas complicações de outras maneiras.

Seja X uma v.a. com f.d.p. $f(\cdot; \theta)$, onde θ é um parâmetro que está em um espaço de parâmetro Θ . Supõe-se que a forma funcional da f.d.p. é completamente conhecido. Portanto, se θ fosse conhecido, a f.d.p. seria conhecido, e consequentemente, poderíamos calcular, em princípio, todas as probabilidades relacionadas a X , a esperança de X , sua variância, etc. O problema, no entanto, é que na maioria das vezes na prática (e no presente contexto) θ não é conhecido. Então o objetivo é estimar θ com base em uma amostra aleatória de tamanho n de $f(\cdot; \theta)$, X_1, \dots, X_n . Então, substituindo θ em $f(\cdot; \theta)$ por uma estimativa "boa" dele,

seria de esperar ser capaz de usar a f.d.p. resultante para os fins descritos acima em um grau satisfatório.

1.3 Estimação de Máxima Verossimilhança: Motivação e Exemplos

O seguinte exemplo simples destina-se a esclarecer o que é intuitivo, mas bastante lógico, o princípio da Estimativa de Máxima Verossimilhança.

Exemplo 1 *Sejam X_1, \dots, X_{10} v.a's i.i.d. da distribuição $B(1, \theta)$, $0 < \theta < 1$, e se X_1, \dots, X_{10} são os respectivos valores observados. Por conveniência, defina $t = x_1 + \dots + x_{10}$. Além disso, suponha que nas 10 tentativas, 6 resultaram em sucessos, de modo que $t = 6$. Então, a função de verossimilhança envolvida é: $L(\theta|x) = \theta^6(1 - \theta)^4$, $0 < \theta < 1$, $\mathbf{x} = (x_1, \dots, x_{10})$. Assim, $L(\theta|x)$ é a probabilidade de observar exatamente 6 sucessos em 10 ensaios binomiais independentes, ocorrendo os sucessos nas tentativas para as quais $x_i = 1, i = 1, \dots, 10$; esta probabilidade é uma função do parâmetro (desconhecido) θ . Vamos calcular os valores desta probabilidade para θ variando de 0,1 a 0,9. Observamos*

Valores de θ	Valores de $L(\theta x)$
0.1	0.0000006561
0.2	0.0000262144
0.3	0.0001750329
0.4	0.0005308416
0.5	0.0009765625
0.6	0.0011943936
0.7	0.0009529569
0.8	0.0004194304
0.9	0.0000531441

que os valores de $L(\theta|x)$, são crescentes, atingem seu máximo valor em $\theta = 0,6$, e então os valores vão diminuindo. Portanto, se esses 9 valores fossem os únicos valores possíveis para θ (o que eles não são!), alguém poderia raciocinar habilmente escolha o valor de 0,6 como o valor de θ . O valor $\theta = 0,6$ tem a distinção de maximizar (entre os 9 valores listados) a probabilidade de atingir os 6 sucessos já observados. Observamos que $0,6 = \frac{6}{10} = \frac{t}{n}$ onde n é o número de tentativas e t

ó o número de sucessos. Veremos no Exemplo a seguir que o valor $\frac{t}{n}$, na verdade, maximiza a função de verossimilhança entre todos os valores de θ com $0 < \theta < 1$. Então $\frac{t}{n}$ será a estimativa de similaridade máxima de θ a ser denotada por $\hat{\theta}$; ou seja, $\hat{\theta} = \frac{t}{n}$.

Definição 1 Sejam X_1, \dots, X_n var. aleatórias independente e identicamente distribuídas(iid) com fdp $f(\cdot; \theta)$ com $\theta \in \Theta$, e sejam x_1, \dots, x_n os respectivos valores observados e $\mathbf{x} = (x_1, \dots, x_n)$. A **função de verossimilhança** $L(\theta|\mathbf{x})$, é definida por:

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i, \theta)$$

o valor de θ que maximiza $L(\theta|\mathbf{x})$ é chamado de **Estimativa de Máxima Verossimilhança (EMV)** de θ . Claramente, a **EMV** depende de \mathbf{x} , e geralmente escrevemos $\hat{\theta} = \hat{\theta}(\mathbf{x})$. Desse modo,

$$L(\hat{\theta}|\mathbf{x}) = \max \{L(\theta|\mathbf{x}), \theta \in \Theta\}.$$

Vamos enunciar agora um resultado muito importante na determinação das **EMV's**

Proposição 1 Dada $f : \Omega \rightarrow \mathbb{R}$, $\Omega \subseteq \mathbb{R}^n$ contínua. Se $\log(f(x))$ possui um máximo x^* em Ω então x^* também é máximo de f .

Prova: Se x^* é um máximo de $\log(f(x))$ então $\log(f(x)) \leq \log(f(x^*))$ para todo $x \in \Omega$ como a função $\log(x)$ é estritamente crescente temos que $f(x) \leq f(x^*)$ para todo $x \in \Omega$ portanto x^* também é um máximo de f .

Exemplo 2 Em termos de uma amostra aleatória de tamanho n , X_1, \dots, X_n de uma distribuição $X \sim B(1, \theta)$ com valores observados x_1, \dots, x_n , determine a **EMV** $\hat{\theta} = \hat{\theta}(\mathbf{x})$ de $\theta \in (0, 1)$, $\mathbf{x} = (x_1, \dots, x_n)$.

Sendo $f(x_i, \theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$, $x_i = 0$ ou 1 , $i = 1, \dots, n$, a função de verossimilhança é dada por:

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^t (1 - \theta)^{n-t}, \quad t = x_1 + \dots + x_n$$

como $x_i = 0$ ou 1 , então $t = 0, 1, \dots, n$. Portanto:

$$\log(L(\theta|\mathbf{x})) = t \log(\theta) + (n - t) \log(1 - \theta)$$

derivando com relação a θ obtemos a equação que denominamos **equação de verossimilhança**

$$\frac{\partial \log(L(\theta|\mathbf{x}))}{\partial \theta} = 0$$

obtendo para este caso:

$$\frac{\partial \log(L(\theta|\mathbf{x}))}{\partial \theta} = \frac{t}{\theta} - \frac{n - t}{1 - \theta} = 0$$

o que concluindo-se que $\theta = \frac{t}{n}$. Fazendo-se agora o teste da derivada segunda temos:

$$\frac{\partial^2 \log(L(\theta|\mathbf{x}))}{\partial \theta^2} = -\frac{t}{\theta^2} - \frac{n - t}{(1 - \theta)^2}$$

como $t \leq n$, $\frac{\partial^2 \log(L(\theta|\mathbf{x}))}{\partial \theta^2} < 0$ para todo θ em particular para $\widehat{\theta} = \frac{t}{n}$.

Portanto o **EMV** de θ é $\widehat{\theta} = \frac{t}{n}$.

Exemplo 3 Determine o **EMV** $\widehat{\theta} = \widehat{\theta}(\mathbf{x})$ de $\theta \in (0, \infty)$ na distribuição $P(\theta)$ (Poisson) em termos de uma amostra aleatória X_1, \dots, X_n com valores observados x_1, \dots, x_n . Sendo $f(x_i, \theta) = \frac{e^{-\theta} \theta^{x_i}}{x_i!}$, $x_i = 0, 1, \dots, i = 1, \dots, n$, a função de verossimilhança é dada por:

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!} = e^{-n\theta} \prod_{i=1}^n \frac{\theta^{x_i}}{x_i!},$$

$$\log(L(\theta|\mathbf{x})) = -n\theta + n \log(\theta) \frac{\sum_{i=1}^n x_i}{n} - \log\left(\prod_{i=1}^n x_i!\right)$$

derivando com relação a θ obtemos a equação que denominamos **equação de verossimilhança**

$$\frac{\partial \log(L(\theta|\mathbf{x}))}{\partial \theta} = 0$$

obtendo para este caso:

$$\frac{\partial \log(L(\theta|\mathbf{x}))}{\partial \theta} = -n + n \frac{\bar{x}}{\theta} = 0$$

o que concluindo-se que $\theta = \bar{x}$. Fazendo-se agora o teste da derivada segunda temos:

$$\frac{\partial^2 \log(L(\theta|\mathbf{x}))}{\partial \theta^2} = -n \frac{\bar{x}}{\theta^2}$$

como $x_i \geq 0, \bar{x} > 0$, logo $\frac{\partial^2 L(\theta|\mathbf{x})}{\partial \theta^2} < 0$ para todo θ em particular para $\widehat{\theta} = \bar{x}$.

Portanto o **EMV** de θ é $\widehat{\theta} = \bar{x} = \frac{\sum_{i=1}^n x_i}{n}$.

Exemplo 4 Determine o **EMV** $\widehat{\theta} = \widehat{\theta}(\mathbf{x})$ de $\theta \in (0, \infty)$ na distribuição Exponencial $\text{Exp}(\theta)$ em termos de uma amostra aleatória X_1, \dots, X_n com valores observados x_1, \dots, x_n .

Nesse caso $f(x_i, \theta) = \theta e^{-\theta x_i}$, $x_i > 0$.

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-n\theta \frac{\sum_{i=1}^n x_i}{n}} = \theta^n e^{-n\theta \bar{x}},$$

$$\log(L(\theta|\mathbf{x})) = n \log(\theta) - n\bar{x}\theta$$

$$\frac{\partial \log(L(\theta|\mathbf{x}))}{\partial \theta} = \frac{n}{\theta} - n\bar{x} = 0$$

conclui-se que $\theta = \frac{1}{\bar{x}}$

$$\frac{\partial^2 \log(L(\theta|\mathbf{x}))}{\partial \theta^2} = -\frac{n}{\theta^2} < 0 \forall \theta$$

em particular para $\widehat{\theta} = \frac{1}{\bar{x}}$. Portanto o **EMV** de θ é $\widehat{\theta} = \frac{1}{\bar{x}} = \frac{n}{\sum_{i=1}^n x_i}$.

Exemplo 5 Seja X_1, \dots, X_n uma amostra aleatória de uma população com distribuição $N(\mu, \sigma^2)$, onde apenas um dos parâmetros é conhecido. Determine a **EMV** do outro (desconhecido) parâmetro.

DISCUSSÃO Com x_1, \dots, x_n sendo valores observados de X_1, \dots, X_n , nós temos:

$$L(\mu, \sigma; \mathbf{x}) = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \right] = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}}, \mu \in \mathbb{R}, \sigma > 0.$$

- Se μ é desconhecido. Então:

$$\log(L(\mu|\mathbf{x})) = -n \log(\sqrt{2\pi}\sigma) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}.$$

Fazendo

$$\frac{\partial \log(L(\mu|\mathbf{x}))}{\partial \mu} = 0,$$

obtemos

$$\frac{(\sum_{i=1}^n x_i) - n\mu}{\sigma^2} = 0.$$

e conseqüentemente

$$\mu = \bar{x}.$$

Como

$$\frac{\partial^2 \log(L(\mu|\mathbf{x}))}{\partial \mu^2} = -\frac{n}{\sigma^2} < 0 \text{ para todo } \mu,$$

concluimos que a **EMV** para μ sendo σ conhecido é $\hat{\mu} = \bar{x}$.

- Se σ^2 é desconhecido. Então:

$$\begin{aligned} \log(L(\sigma^2|\mathbf{x})) &= -n \log(\sqrt{2\pi}\sigma) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}. \end{aligned}$$

Fazendo

$$\frac{\partial \log(L(\sigma^2|\mathbf{x}))}{\partial \sigma^2} = 0,$$

obtemos

$$-\frac{n\sigma^2}{2\sigma^4} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} = 0.$$

e conseqüentemente

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n} = s^2.$$

Como

$$\begin{aligned} \frac{\partial^2 \log(L(\sigma^2|\mathbf{x}))}{\partial (\sigma^2)^2} &= \frac{n}{2\sigma^4} - \frac{2 \sum_{i=1}^n (x_i - \mu)^2}{2\sigma^6} \\ &= \frac{n}{2(\sigma^2)^2} - \frac{2n}{2(\sigma^2)^3} \frac{\sum_{i=1}^n (x_i - \mu)^2}{n} \\ &= \frac{n}{2(\sigma^2)^2} - \frac{2n}{2(\sigma^2)^3} s^2 \\ \frac{\partial^2 \log(L(\sigma^2|\mathbf{x}))}{\partial (\sigma^2)^2} \Big|_{\sigma^2=s^2} &= \frac{n}{2(s^2)^2} - \frac{2n}{2(s^2)^3} s^2 \\ &= -\frac{n}{2(s^2)^2} < 0. \end{aligned}$$

Portanto a **EMV** para σ^2 com conhecido é $\widehat{\sigma^2} = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$.

Exemplo 6 Seja X_1, \dots, X_n uma amostra aleatória de uma população com distribuição $\mathcal{U}(\alpha, \beta)$, onde apenas um dos parâmetros é conhecido. Determine a **EMV** do outro (desconhecido) parâmetro.

DISCUSSÃO Com x_1, \dots, x_n sendo valores observados de X_1, \dots, X_n , nós temos:

$$L(\alpha, \beta|\mathbf{x}) = \frac{1}{(\beta - \alpha)^n} \prod_{i=1}^n I_{[\alpha, \beta]}(x_i) = \frac{1}{(\beta - \alpha)^n} I_{[\alpha, \beta]}(x_{\min}) \times I_{[\alpha, \beta]}(x_{\max})$$

onde

$$I_{[\alpha, \beta]}(x) = I(\alpha \leq x \leq \beta) = \begin{cases} 1, & \text{se } \alpha \leq x \leq \beta \\ 0 & \text{caso contrário} \end{cases}$$

é a função indicadora do intervalo $[\alpha, \beta]$, $x_{\min} = \min \{x_1, \dots, x_n\}$ e $x_{\max} = \max \{x_1, \dots, x_n\}$.

- Se α é desconhecido.

$$\beta - \alpha \geq \beta - x_{\min} \Rightarrow \frac{1}{(\beta - \alpha)^n} \leq \frac{1}{(\beta - x_{\min})^n}$$

portanto $\alpha = x_{\min}$ e consequentemente $\hat{\alpha} = x_{\min}$ é a **EMV** de α .

- Se β é desconhecido.

$$\beta - \alpha \geq x_{\max} - \alpha \Rightarrow \frac{1}{(\beta - \alpha)^n} \leq \frac{1}{(x_{\max} - \alpha)^n}$$

portanto $\beta = x_{\max}$ e consequentemente $\hat{\beta} = x_{\max}$ é a **EMV** de β .

Exemplo 7 Seja X_1, \dots, X_n uma amostra aleatória de uma população com distribuição $N(\mu, \sigma^2)$, onde os dois parâmetros são desconhecidos. Determine as **EMV's** desses parâmetros.

$$\log(L(\mu, \sigma^2 | \mathbf{x})) = -n \log(\sqrt{2\pi}\sigma) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}.$$

$$\nabla \log(L(\mu, \sigma^2 | \mathbf{x})) = \begin{pmatrix} \frac{(\sum_{i=1}^n x_i) - n\mu}{\sigma^2} \\ -\frac{n\sigma^2}{2\sigma^4} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} \end{pmatrix}$$

Fazendo

$$\nabla \log(L(\mu, \sigma^2 | \mathbf{x})) = \mathbf{0}$$

Obtemos a única solução (μ, σ^2) deste sistema de equações não lineares dada por:

$$\mu = \frac{\sum_{i=1}^n x_i}{n} \text{ e } \sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$

A matriz Hessiana de $\log(L(\mu, \sigma^2|\mathbf{x}))$ é dada por:

$$\nabla^2 \log(L(\mu, \sigma^2|\mathbf{x})) = \begin{pmatrix} -\frac{n}{\sigma^2} & 2 \frac{(\sum_{i=1}^n x_i - n\mu)}{2\sigma^4} \\ -\frac{\sum_{i=1}^n x_i - n\mu}{(\sigma^2)^2} & \frac{n}{2(\sigma^2)^2} - \frac{2n}{2(\sigma^2)^3} s^2 \end{pmatrix}$$

Substituindo nos valores obtidos de $\widehat{\mu}$ e $\widehat{\sigma^2}$ obtemos:

$$\nabla^2 \log(L(\widehat{\mu}, \widehat{\sigma^2}|\mathbf{x})) = \begin{pmatrix} -\frac{n}{\sigma^2} & 0 \\ 0 & -\frac{n}{2(s^2)^2} \end{pmatrix}$$

Como $\nabla^2 \log(L(\widehat{\mu}, \widehat{\sigma^2}|\mathbf{x}))$ é uma matriz definida negativa o par $(\widehat{\mu}, \widehat{\sigma^2})$ é uma **EMV** para (μ, σ^2) .

Exemplo 8 Um experimento multinomial é realizado independentemente n vezes, de modo que a função de verossimilhança é dada por:

$$L(\theta_1, \dots, \theta_r|\mathbf{x}) = \frac{n!}{\prod_{i=1}^n x_i!} \theta_1^{x_1}, \dots, \theta_r^{x_r},$$

onde $x_i \geq 0$ e inteiro, $\sum_{i=1}^r x_i = n$, $0 < p_i < 1$, $\sum_{i=1}^r \theta_i = 1$, $i = 1, \dots, r$. Determine as **EMV's** para \mathbf{p} .

DISCUSSÃO: Nesse caso trata-se de um problema de otimização com uma restrição de igualdade:

$$\begin{aligned} \text{Maximize } \log(L(\theta_1, \dots, \theta_r|\mathbf{x})) &= \sum_{i=1}^r x_i \log(\theta_i) - n! \log\left(\prod_{i=1}^n x_i!\right) \\ \text{Sujeito à: } \sum_{i=1}^r \theta_i &= 1, \quad \theta_i > 0 \end{aligned}$$

Cuja função Lagrangeana associada $\mathcal{L} : \mathbb{R}^r \times \mathbb{R} \rightarrow \mathbb{R}$ é dada por:

$$\mathcal{L}(\theta, \lambda) = \sum_{i=1}^r x_i \log(\theta_i) - n! \log\left(\prod_{i=1}^n x_i!\right) - \lambda \left(\sum_{i=1}^r \theta_i - 1\right)$$

com as seguintes condições de otimalidade de 1^a. ordem:

$$\nabla \mathcal{L}(\boldsymbol{\theta}, \lambda) = \mathbf{0} \Leftrightarrow \frac{x_i}{\theta_i} - \lambda = 0, \quad i = 1, \dots, r.$$

$$\sum_{i=1}^r \theta_i = 1.$$

$\frac{x_i}{\theta_i} - \lambda = 0, \quad i = 1, \dots, r$, nos diz que $\theta_i = \frac{x_i}{\lambda}$, como $\sum_{i=1}^r \theta_i = 1$. substituindo os valores de θ_i nessa equação obtemos $\lambda = \sum_{i=1}^r x_i = n$ obtendo finalmente $\theta_i = \frac{x_i}{n}$. Portanto $\widehat{\boldsymbol{\theta}} = \frac{\mathbf{x}}{n}$, uma vez que a matriz Hessiana da função $\nabla^2 L(\boldsymbol{\theta})$ dada por:

$$\nabla^2 L(\boldsymbol{\theta}) = \begin{pmatrix} -\frac{x_1}{\theta_1^2} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & -\frac{x_r}{\theta_r^2} \end{pmatrix} \text{ é Semidefinida Negativa isto é:}$$

$$\sum_{i=1}^r \sum_{j=1}^r \frac{\partial^2 L(\boldsymbol{\theta}, \lambda)}{\partial \theta_i \partial \theta_j} v_i v_j = - \sum_{i=1}^r \frac{x_i}{\theta_i^2} v_i^2 < 0 \text{ para todo } \mathbf{v} \in \mathbb{R}^r.$$

1.3.1 A Família Exponencial e os Estimadores de Máxima Verossimilhança

Definição 2 (Família Exponencial: O caso Uniparamétrico)

Uma fdp $f(\cdot; \theta), \theta \in \Theta \subseteq \mathbb{R}$ pertence a Família Exponencial, se $f(x; \theta)$ é da forma:

$$f(x; \theta) = C(\theta) e^{Q(\theta)T(x)} \times h(x)$$

onde Q é estritamente monótona e h não envolve θ , $C(\theta)$ é simplesmente uma constante de normalização.

Vejamos alguns exemplos de membros dessa família

Exemplo 9 Se $X \sim \mathcal{B}(n, \theta)$

$$f(x; \theta) = \frac{n!}{(n-x)!x!} \theta^x (1-\theta)^{n-x} I_A(x)$$

onde $A = \{1, 2, \dots, n\}$. Podemos escrever esta fdp da seguinte forma:

$$\begin{aligned}
f(x; \theta) &= (1 - \theta)^n \frac{n!}{(n - x)!x!} \left(\frac{\theta}{1 - \theta} \right)^x I_A(x) \\
&= (1 - \theta)^n \frac{n!}{(n - x)!x!} e^{\ln\left[\left(\frac{\theta}{1 - \theta}\right)^x\right]} I_A(x) \\
&= (1 - \theta)^n e^{\ln\left(\frac{\theta}{1 - \theta}\right)x} \frac{n!}{(n - x)!x!} I_A(x)
\end{aligned}$$

Fazendo $C(\theta) = (1 - \theta)^n$, $Q(\theta) = \ln\left(\frac{\theta}{1 - \theta}\right)$, $T(x) = x$ e $h(x) = \frac{n!}{(n - x)!x!}$ vemos que $f(x; \theta)$ é um membro da família exponencial.

Exemplo 10 Se $X \sim \mathcal{N}(\mu, \sigma^2)$ e μ é conhecido então $\sigma^2 = \theta$, logo

$$f_X(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$$

Se σ^2 é conhecido então $\mu = \theta$, logo

$$\begin{aligned}
f(x; \theta) &= \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x-\theta)^2}{2\sigma^2}}, -\infty < x < \infty \\
&= \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{x^2 - 2\theta x + \theta^2}{2\sigma^2}}, -\infty < x < \infty \\
&= \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{\theta^2}{2\sigma^2}} e^{\frac{\theta}{\sigma^2}x} e^{-\frac{x^2}{2\sigma^2}}, -\infty < x < \infty
\end{aligned}$$

Se μ é conhecido então $\sigma^2 = \theta$, logo

$$\begin{aligned}
f(x; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty \\
f(x; \theta) &= \frac{1}{\sqrt{2\pi\theta}} e^{-\frac{(x-\mu)^2}{2\theta}} \\
&= \frac{1}{\sqrt{2\pi\theta}} e^{-\frac{1}{2\theta}(x-\mu)^2}
\end{aligned}$$

Fazendo $C(\theta) = \frac{1}{\sqrt{2\pi\theta}}$, $Q(\theta) = e^{\frac{1}{2\theta}}$, $T(x) = e^{-(x-\mu)^2}$ e $h(x) = 1$, vemos que $f(x; \theta)$ é um membro da família exponencial.

Definição 3 (Família Exponencial: O caso Multiparamétrico)

Sejam X_1, \dots, X_r var aleat. iid e $\mathbf{X} = (X_1, \dots, X_r)^t$, dizemos que sua fdp conjunta pertence a a r -paramétrica família exponencial se ela puder ser escrita da seguinte forma:

$$f(\mathbf{x}; \boldsymbol{\theta}) = C(\boldsymbol{\theta}) \exp \left[\sum_{j=1}^r Q_j(\boldsymbol{\theta}) T_j(\mathbf{x}) \right] h(\mathbf{x})$$

onde $\mathbf{x} = (x_1, \dots, x_n)^t$, $x_i \in \mathbb{R}$ $i = 1, \dots, r$, $\boldsymbol{\theta} = (\theta_1, \dots, \theta_r)^t \in \Theta \subset \mathbb{R}^r$, $C(\boldsymbol{\theta}) > 0$ e $h(\mathbf{x}) > 0$ para $\mathbf{x} \in S$ sendo S o conjunto onde f é positiva.

Exemplo 11 A distribuição Multinomial

$$f(\mathbf{x}) = \frac{n!}{\prod_{j=1}^r x_j!} \prod_{j=1}^r p_j^{x_j}, \quad \sum_{j=1}^r p_j = 1, \quad p_j > 0.$$

$$\begin{aligned} f(\mathbf{x}; \boldsymbol{\theta}) &= \frac{n!}{\prod_{j=1}^r x_j!} \prod_{j=1}^r \theta_j^{x_j} \quad \sum_{j=1}^r \theta_j = 1, \quad \theta_j > 0. \\ &= \frac{n!}{\prod_{j=1}^r x_j!} \theta_r^r \prod_{j=1}^r \left(\frac{\theta_j}{\theta_r} \right)^{x_j} \\ &= \frac{n!}{\prod_{j=1}^r x_j!} (1 - \theta_1 - \theta_2 - \dots - \theta_{r-1})^r \prod_{j=1}^r \left(\frac{\theta_j}{1 - \theta_1 - \theta_2 - \dots - \theta_{r-1}} \right)^{x_j} \\ &= (1 - \theta_1 - \theta_2 - \dots - \theta_{r-1})^r \exp \left[\sum_{j=1}^r x_j \log \left(\frac{\theta_j}{1 - \theta_1 - \theta_2 - \dots - \theta_{r-1}} \right) \right] \frac{n!}{\prod_{j=1}^r x_j!} \end{aligned}$$

$$\begin{aligned} C(\boldsymbol{\theta}) &= (1 - \theta_1 - \theta_2 - \dots - \theta_{r-1})^r, \quad Q_j(\boldsymbol{\theta}) = \log \left(\frac{\theta_j}{1 - \theta_1 - \theta_2 - \dots - \theta_{r-1}} \right), \quad T(\mathbf{x}) = \mathbf{x} \\ h(\mathbf{x}) &= \frac{n!}{\prod_{j=1}^r x_j!} \end{aligned}$$

Exemplo 12 A distribuição Normal. Se $X \sim N(\theta_1, \theta_2)$ vamos mostrar que X também é um membro de uma 2 paramétrica família exponencial

$$\begin{aligned} f(x; \theta_1, \theta_2) &= \frac{1}{\sqrt{2\pi\theta_2}} e^{-\frac{(x-\theta_1)^2}{2\theta_2}}, -\infty < x < \infty \\ &= \frac{1}{\sqrt{2\pi\theta_2}} e^{-\frac{x^2 - 2\theta_1 x + \theta_1^2}{2\theta_2}} = \frac{e^{-\frac{\theta_1^2}{2\theta_2}}}{\sqrt{2\pi\theta_2}} e^{-\frac{1}{2\theta_2}x^2 + \frac{\theta_1}{\theta_2}x} \end{aligned}$$

Fazendo $C(\theta) = \frac{e^{-\frac{\theta_1^2}{2\theta_2}}}{\sqrt{2\pi\theta_2}}$, $Q(\theta) = \left(\frac{1}{2\theta_2}, \frac{\theta_1}{\theta_2}\right)^t$ e $T(x) = (-x^2, x)^t$ podemos ver que trata-se de um membro da bi-paramétrica família exponencial.

1.3.2 Exercícios

1.1 Se X_1, \dots, X_n são r.v. independentes distribuídos como $B(k, \theta)$, $\theta \in \Theta = (0, 1)$, com os respectivos valores observados x_1, \dots, x_n , mostre que $\hat{\theta} = \frac{\bar{x}}{k}$ é a EMV de θ , onde \bar{x} é a média da amostra dos x_i 's.

1.2 Se as v.a's independentes. X_1, \dots, X_n têm distribuição geométrica com fdp:

$$f(x; \theta) = \theta(1 - \theta)^{x-1}, \quad x = 1, 2, \dots, \quad \theta \in \Theta = (0, 1),$$

e respectivos valores observados x_1, \dots, x_n , mostre que $\hat{\theta} = \frac{1}{\bar{x}}$ é a EMV de θ .

1.3 Com base em uma amostra aleatória de tamanho n com fdp: $f(x; \theta) = (\theta + 1)x^\theta$, $0 < x < 1$, $\theta \in \Theta = (-1, \infty)$, encontre a EMV de θ .

1.4 Com base em uma amostra aleatória de tamanho n de de uma v.a com fdp. $f(x; \theta) = \theta x^{\theta-1}$, $\theta < x < 1$, $\theta \in \Theta = (0, \infty)$, encontre a EMV de θ .

1.5 i- Mostre que a função $f(x; \theta) = \frac{1}{2\theta} e^{-|x|/\theta}$, $x \in \mathbb{R}$, $\theta \in \Theta = (0, \infty)$ é uma fdp, e desenhe seu gráfico. (f é a chamada Exponencial Dupla),

ii- Com base em uma amostra aleatória desta fdp., encontre a EMV de θ .

1.6 i - Verifique que a função $f(x; \theta) = \theta^2 x e^{-\theta x}$, $x > 0$ $\theta \in \Theta = (0, \infty)$ é uma fdp, observando que a mesma é uma distribuição Gamma e exibindo seus parâmetros.

- ii - Com base em uma amostra aleatória desta fdp., encontre a **EMV** de θ .
- 1.7 i - Mostre que a função $f(x; \alpha, \beta) = \frac{1}{\beta} e^{-\frac{(x-\alpha)}{\beta}}$, $x \geq \alpha$, $\alpha \in \mathbb{R}$ $\beta > 0$ é uma fdp. Com base em uma amostra aleatória desta fdp., encontre a **EMV** de:
- ii - α quando β é conhecido.
- iii - β quando α é conhecido.
- iv - β e α quando ambos são desconhecidos.
- 1.8 Em cada um dos seguintes casos, mostre que a distribuição da v.a. X é um membro da *família exponencial* de um parâmetro e identificando as funções $C(\theta)$, $Q(\theta)$ e $h(x)$ que a caracterizam.
- i X tem distribuição de Poisson;
- ii X tem distribuição Binomial Negativa;
- iii X tem distribuição Gamma com β conhecido;
- iv X tem distribuição Gamma com α conhecido;
- v X tem distribuição Beta com β conhecido;
- vi X tem distribuição Beta com α conhecido;
- 1.9 Em cada um dos seguintes casos, mostre que a distribuição do v.a X e o vetor aleatório \mathbf{X} são da *família exponencial* multiparamétrica e identificando as várias funções que os caracterizam.
- i X tem distribuição Gamma;
- ii X tem distribuição Beta;
- iii $\mathbf{X} = (X_1, X_2)$ tem distribuição Normal Bivariada;

1.4 Propriedades das EMV's

Teorema 1 (Invariância) Seja $\widehat{\theta} = \widehat{\theta}(\mathbf{x})$ a **EMV** de θ com base nos valores observados x_1, \dots, x_n da amostra aleatória X_1, \dots, X_n de uma fdp $f(\cdot; \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$. Também, seja $\theta^* = g(\theta)$ uma função injetiva definida de Θ para $\Theta^* \subseteq \mathbb{R}$. Então a **EMV** de θ^* , $\widehat{\theta}^*$, é dada por $\widehat{\theta}^*(\mathbf{x}) = g[\widehat{\theta}(\mathbf{x})]$.

Prova: Seja $\Theta^* = g(\Theta)$ e $L^* : \Theta^* \rightarrow \mathbb{R}$ definida por $L^*(\theta^*) = L(g^{-1}(\theta^*)|\mathbf{x})$, a injetividade de g garante a existência da $g^{-1} : \Theta^* \rightarrow \Theta$. Se $L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i; \theta)$ possui um máximo, então:

$$L(\widehat{\theta}|\mathbf{x}) = \max L(\theta|\mathbf{x}) = \max L^*(\theta^*|\mathbf{x}) = L^*(\widehat{\theta}^*|\mathbf{x})$$

Da construção de L^* temos: $L(\theta|\mathbf{x}) = L^*(g(\theta)|\mathbf{x})$ para todo $\theta \in \Theta$, como $\widehat{\theta}^* = g(\widehat{\theta})$, segue que $g(\widehat{\theta}) = g(\widehat{\theta}^*)$ provando o resultado.

Exemplo 13 Se $\widehat{\theta}$ é a **EMV** de uma v.a. $X \sim \mathcal{P}(\theta)$ e $g(\theta) = \exp(-\theta)$ como $\widehat{\theta} = \bar{x}$, $g(\widehat{\theta}) = \exp(-\bar{x})$ para $h(\theta) = \frac{1}{\theta}$ $\widehat{h(\theta)} = \frac{1}{\bar{x}}$ pois ambas g e h são funções injetivas. da mesma forma quando temos $X \sim \mathcal{N}(\mu, \sigma^2)$, $\widehat{\sigma^2} = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$, fazendo tomando $h(\theta) = \sqrt{\theta}$ temos $\sigma = \sqrt{\widehat{\sigma^2}} = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n}}$.

Teorema 2 Seja $\widehat{\theta} = \widehat{\theta}(\mathbf{x})$ a **EMV** de θ com base nos valores observados x_1, \dots, x_n da amostra aleatória X_1, \dots, X_n de uma fdp $f(\cdot; \theta), \theta \in \Theta \subseteq \mathbb{R}$. Também, seja $\theta^* = g(\theta)$ definida de Θ para $\Theta^* \subseteq \mathbb{R}$ tal que a imagem de g seja Θ^* . Então a **EMV** de $\theta^*, \widehat{\theta}^*$, é dada por $\widehat{\theta}^*(\mathbf{x}) = g[\widehat{\theta}(\mathbf{x})]$.

Prova: Diferente do teorema anterior aqui não temos a hipótese da injetividade, logo pode existir em Θ vários θ 's tais que $g(\theta) = \theta^* \in \Theta^*$, nesse caso vamos definir para cada $\theta^* \in \Theta^*$ o conjunto de nível:

$$\Theta_{\theta^*} = \{\theta \in \Theta; g(\theta) = \theta^*\}$$

e em seguida definimos a função de verossimilhança induzida por g $L^* : \Theta_{\theta^*} \rightarrow \mathbb{R}$ dada por:

$$L^*(\theta^*) = \sup \{L(\theta) \mid \theta \in \Theta_{\theta^*}\}$$

Se $\widehat{\theta}$ é a **EMV** de θ existe um único $\widehat{\theta}^* \in \Theta^*$ tal que $g(\widehat{\theta}) = \widehat{\theta}^*$ e

$$L^*(\widehat{\theta}^*) = \sup \{L(\theta); \theta \in \Theta_{\widehat{\theta}^*}\} = \sup \{L(\theta); \theta \in \Theta; g(\theta) = g(\widehat{\theta})\} = L(\widehat{\theta})$$

Agora, para todo $\theta^* \in \Theta^*$

$$L^*(\theta^*) = \sup \{L(\theta) \mid \theta \in \Theta_{\theta^*}\} \leq \max \{L(\theta); \theta \in \Theta\} = L(\widehat{\theta}) = L^*(\widehat{\theta}^*)$$

Esta última desigualdade mostra que $\widehat{\theta}^* = g(\widehat{\theta})$, provando assim o resultado.

Exemplo 14 Em termos de uma amostra aleatória de tamanho n , X_1, \dots, X_n de uma distribuição $X \sim B(1, \theta)$ com valores observados x_1, \dots, x_n , determine a **EMV** $\widehat{\theta} = \widehat{\theta}(\mathbf{x})$ de $\theta \in (0, 1)$, $\mathbf{x} = (x_1, \dots, x_n)$. Sendo $f(x_i, \theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$, $x_i = 0$ ou $1, i = 1, \dots, n$, a função de verossimilhança é dada por:

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^t (1 - \theta)^{n-t}, \quad t = x_1 + \dots + x_n$$

,portanto o **EMV** de θ é $\widehat{\theta} = \frac{t}{n}$. Se $g(\theta) = \theta(1 - \theta)$ determine $\widehat{g(\theta)}$. Nesse caso a função $g : (0, 1) \rightarrow (0, \frac{1}{4})$ não é injetiva mas pelo teorema acima:

$$\widehat{g(\theta)} = g(\widehat{\theta}) = \widehat{\theta}(1 - \widehat{\theta}) = \frac{t}{n}(1 - \frac{t}{n}).$$

Definição 4 (Suficiência)

Sejam X_1, \dots, X_n é uma amostra aleatória com fdp $f(\cdot; \theta), \theta \in \Theta \subseteq \mathbb{R}$, e seja $T = T(X_1, \dots, X_n)$ uma estatística. (uma função conhecida dos X_i 's). Então, se as distribuições condicionais dos X_i 's, dado $T = t$, não depende de θ dizemos que T é uma estatística suficiente para θ .

Teorema 3 (Fatorização de Fisher-Neyman) Sejam X_1, \dots, X_n é uma amostra aleatória com fdp $f(\cdot; \theta), \theta \in \Theta \subseteq \mathbb{R}$, e seja $T = T(X_1, \dots, X_n)$ uma estatística. Então, T é uma estatística suficiente para θ se e somente se a fdp conjunta dos X_i 's pode ser escrita da seguinte forma:

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n; \theta) = g[T(X_1, \dots, X_n; \theta)] \times h(x_1, \dots, x_n)$$

Prova: Não será feita neste curso.

Exemplo 15 Se $X_1, \dots, X_n \sim \mathcal{B}(1, p)$ e são v.a. ind. com f.d.p's

$$f(x; \theta) = \theta^{x_i} (1 - \theta)^{1-x_i} I_{\{0,1\}}(x_i), \quad i = 1, \dots, n$$

a distribuição conjunta de f é

$$L(\theta) = \theta^t (1 - \theta)^{n-t} \times \prod_{i=1}^n I_{\{0,1\}}(x_i), \quad \text{onde } t = \sum_{i=1}^n x_i.$$

Fazendo $g(T(\mathbf{x}), \theta) = \theta^t (1 - \theta)^{n-t}$, e $h(\mathbf{x}) = \prod_{i=1}^n I_{\{0,1\}}(x_i)$ vemos que $L(\theta) = g(T(\mathbf{x}), \theta) \times h(\mathbf{x})$ e h independe de θ portanto $T = \sum_{i=1}^n X_i = n\bar{X}$ é uma estatística suficiente para θ .

Exemplo 16 Se $X \sim \mathcal{P}(\theta)$ com $f(x, \theta) = e^{-\theta} \frac{\theta^x}{x!}$, $x = 0, 1, \dots$, $\theta > 0$.

$$L(\theta) = e^{-n\theta} \prod_{i=1}^n \frac{\theta^{x_i}}{x_i!} = e^{-n\theta} \theta^{\sum_{i=1}^n x_i} \frac{1}{\prod_{i=1}^n x_i!}$$

Concluimos que $f(\mathbf{x}, \theta) = g(T(\mathbf{x}), \theta) \times h(\mathbf{x})$ onde $g(T(\mathbf{x}), \theta) = e^{-n\theta} \theta^{\sum_{i=1}^n x_i}$ e $h(\mathbf{x}) = \frac{1}{\prod_{i=1}^n x_i!}$ portanto $T = \sum_{i=1}^n X_i = n\bar{X}$ é uma estatística Suficiente para θ .

Exemplo 17 Se $X \sim \text{Exp}(\theta)$ com $f(x_i, \theta) = \theta e^{-\theta x_i}$, $x_i > 0$.

$$f(\mathbf{x}, \theta) = \prod_{i=1}^n f(x_i, \theta) = L(\theta) = \theta^n e^{-(\theta \sum_{i=1}^n x_i)}$$

Concluimos que $f(\mathbf{x}, \theta) = g(T(\mathbf{x}), \theta) \times h(\mathbf{x})$ onde $g(T(\mathbf{x}), \theta) = \theta^n e^{-\theta(\sum_{i=1}^n x_i)}$ e $h(\mathbf{x}) = 1$ portanto $T = \sum_{i=1}^n X_i = n\bar{X}$ é uma estatística Suficiente para θ .

Exemplo 18 Seja X_1, \dots, X_n uma amostra aleatória de uma população com distribuição $N(\mu, \sigma^2)$:

$$L(\mu, \sigma; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}}, \mu \in \mathbb{R}, \sigma > 0.$$

Se μ é desconhecido

$$L(\mu; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{\sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2)}{2\sigma^2}} = e^{-\frac{-2\mu(\sum_{i=1}^n x_i + \mu)}{2\sigma^2}} \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{\sum_{i=1}^n x_i^2}{2\sigma^2}}, \mu \in \mathbb{R}.$$

Observamos que $T(\mathbf{x}) = \sum_{i=1}^n x_i$ e também \bar{X} são estatísticas suficientes para μ .

Se σ^2 é desconhecido

$$L(\sigma^2; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^n e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}} \times 1.$$

$T(\mathbf{x}) = \sum_{i=1}^n (x_i - \mu)^2$ e também $T(\mathbf{x}) = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$ são estatísticas suficientes para σ^2 .

Finalmente, se μ e σ^2 é desconhecidos

$$\begin{aligned} L(\mu, \sigma^2; \mathbf{x}) &= \left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^n e^{-\frac{\sum_{i=1}^n (x_i - \bar{x} + \bar{x} - \mu)^2}{2\sigma^2}} \\ &= \left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^n e^{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)(\sum_{i=1}^n x_i - n\bar{x}) - n(\bar{x} - \mu)^2}{2\sigma^2}} \\ &= \left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^n e^{-\left(-\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2\sigma^2} - n\frac{(\bar{x} - \mu)^2}{2\sigma^2} \right)} \end{aligned}$$

As estatísticas $(\bar{X}, \sum_{i=1}^n (X_i - \bar{X})^2)$ formam um par de estatísticas suficientes para o par (μ, σ^2) .

Exemplo 19 Com base em uma amostra aleatória de tamanho n , X_1, \dots, X_n , de cada uma das f.d.p's dadas abaixo com valores observados x_1, \dots, x_n , determine uma estatística suficiente estatística para θ

- i- $f(x; \theta) = \frac{\theta}{x^{\theta+1}}, x \geq 1, \theta \in \Theta = (0, \infty).$
- ii- $f(x; \theta) = \frac{x}{\theta} e^{-\frac{x^2}{2\theta}}, x > 0, \theta \in \Theta = (0, \infty).$
- iii- $f(x; \theta) = (1 + \theta) x^\theta, 0 < x < 1, \theta \in \Theta = (-1, \infty).$
- iv- $f(x; \theta) = \frac{\theta}{x^2}, x \geq 0, \theta \in \Theta = (0, \infty).$

.

Solução Se $x_{\min} = \min \{x_1, \dots, x_n\}$ e $x_{\max} = \max \{x_1, \dots, x_n\}$

- i- $f(x; \theta) = \frac{\theta}{x^{\theta+1}}$ logo

$$\begin{aligned} f(\mathbf{x}, \theta) &= \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \frac{\theta}{x_i^{\theta+1}} \prod_{i=1}^n I_{(1, \infty)}(x_i) \\ &= \frac{\theta^n}{\prod_{i=1}^n x_i^{\theta+1}} I_{(1, \infty)}(x_{\min}). \end{aligned}$$

Portanto $T(\mathbf{X}) = \prod_{i=1}^n X_i$ é uma estatística suficiente para θ .

- ii- Se $f(x; \theta) = \frac{x}{\theta} e^{-\frac{x^2}{2\theta}} I_{(1, \infty)}(x)$ logo

$$\begin{aligned} f(\mathbf{x}; \theta) &= \prod_{i=1}^n f(x_i, \theta) \\ &= \prod_{i=1}^n \frac{x_i}{\theta} e^{-\frac{x_i^2}{2\theta}} \prod_{i=1}^n I_{(1, \infty)}(x_i) \\ &= \frac{e^{-\frac{\sum_{i=1}^n x_i^2}{2\theta}}}{\theta^n} \times \prod_{i=1}^n x_i I_{(1, \infty)}(x_{\min}). \end{aligned}$$

Portanto $T(\mathbf{X}) = \sum_{i=1}^n X_i^2$ é uma estatística suficiente para θ .

- iii- Se $f(x; \theta) = (1 + \theta) x^\theta I_{(0, 1)}(x)$ logo

$$\begin{aligned} f(\mathbf{x}; \theta) &= \prod_{i=1}^n f(x_i, \theta) \\ &= \prod_{i=1}^n (1 + \theta)^n \prod_{i=1}^n x_i^\theta \prod_{i=1}^n I_{(0, 1)}(x_i) \\ &= \prod_{i=1}^n (1 + \theta)^n (\prod_{i=1}^n x_i)^\theta I_{(0, 1)}(x_{\min}) \times I_{(0, 1)}(x_{\max}). \end{aligned}$$

Portanto $T(\mathbf{X}) = \prod_{i=1}^n X_i$ é uma estatística suficiente para θ .

iv- Se $f(x; \theta) = \frac{\theta}{x_i^2} I_{(\theta, \infty)}(x)$ logo

$$f(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \frac{\theta}{x_i^2} \prod_{i=1}^n I_{(\theta, \infty)}(x_i) = \theta^n I_{(\theta, \infty)}(x_{\min}) \frac{1}{\prod_{i=1}^n x_i^2}.$$

Portanto $T(\mathbf{X}) = X_{\min} = \min\{X_1, \dots, X_n\}$ é uma estatística suficiente para θ .

Teorema 4 Se $\widehat{\theta}_n = \widehat{\theta}_n(X_1, \dots, X_n)$ é a **EMV** de $\theta \in \Theta \subseteq \mathbb{R}$ baseada numa amostra aleatória (X_1, \dots, X_n) com fdp $f(\cdot; \theta)$. Então, sob certas condições de regularidade $\{\widehat{\theta}_n\}$ é consistente no sentido de probabilidade, isto é: $\widehat{\theta}_n \rightarrow \theta$ em P_θ — Probabilidade quando $n \rightarrow \infty$

Prova: Não será feita neste curso.

Teorema 5 Se $\widehat{\theta}_n = \widehat{\theta}_n(X_1, \dots, X_n)$ é a **EMV** de $\theta \in \Theta \subseteq \mathbb{R}$ baseada numa amostra aleatória X_1, \dots, X_n com fdp $f(\cdot; \theta)$. Então, sob certas condições de regularidade $\{\widehat{\theta}_n\}$ é assintoticamente normal, isto é:

$$\sqrt{n}(\widehat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma_\theta^2)$$

onde

$$\sigma_\theta^2 = 1/I(\theta) e I(\theta) = E_\theta \left[\frac{\partial \log(f(X; \theta))}{\partial \theta} \right]^2, \quad X \sim f(\cdot; \theta).$$

Prova: Não será feita neste curso.

1.4.1 Exercícios

1- Se X_1, \dots, X_n são v.a's i.i.d tendo fdp com distribuição exponencial $f(x, \theta) = \theta e^{-\theta x}$, $x > 0, \theta \in \Theta = (0, \infty)$. Então:

a Mostre que $1/\bar{X}$ é uma **EMV** de θ ;

b Use Teorema 1 com o objetivo de provar que **EMV** de θ^* na forma parametrizada $f(x; \theta^*) = \frac{1}{\theta^*} e^{-x/\theta^*}$, $x > 0$, é \bar{X} .

- 2- Seja X uma v.a que denota a vida útil de um equipamento. Então a confiabilidade do equipamento no tempo x , $R(x)$, é definido como a probabilidade de que $X > x$, isto é $R(x) = P(X > x)$. Suponha agora que X tem fdp com distribuição Exponencial $f(x, \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $x > 0, \theta \in \Theta = (0, \infty)$. Então:
- Calcule a confiabilidade de $R(x, \theta)$ com base nesta v.a X ;
 - Use Teorema 1 com o objetivo de encontrar que **EMV** de $R(x, \theta)$ com base de uma amostra aleatória X_1, \dots, X_n da fdp. dada.
- 3- Seja X uma v.a. descrevendo a vida útil de um determinado equipamento, e suponha que a f.d.p. de X é $f(x, \theta) = \theta e^{-\theta x}$, $x > 0, \theta \in \Theta = (0, \infty)$. Então:
- Mostre que a probabilidade de que X seja maior ou igual ao tempo t unidades é $g(\theta) = e^{-t\theta}$;
 - Sabemos (ver Exercício 1) que a **EMV** de θ , com base em uma amostra de tamanho n da f.d.p. acima, é $\widehat{\theta} = 1/\bar{X}$. Então determine a **EMV** de $g(\theta)$.
- 4- Considere n variáveis aleatórias independentes e identicamente distribuídas com fdp com distribuição Weibull $f(x, \theta) = \frac{\gamma}{\theta} x^{\gamma-1} e^{-\frac{x^\gamma}{\theta}}$, $x > 0, \gamma > 0$ conhecido, $\theta \in \Theta = (0, \infty)$
- Mostre que a $\widehat{\theta} = \frac{\sum_{i=1}^n X_i^\gamma}{n}$ é a **EMV** de θ ;
 - Tome $\gamma = 1$ e relacione o resultado na parte (a) ao resultado do Exercício 1 item (b).
- 5- Se X_1, \dots, X_n é uma amostra aleatória de tamanho n de uma distribuição normal $\mathcal{N}(\mu, \sigma^2)$ onde μ, σ são desconhecidos. Se $\theta = (\mu, \sigma^2)$ e $0 < p < 1$ é um número conhecido. Então:
- Mostre que o ponto c para o qual temos $P_\theta(\bar{X} \leq c) = p$ é dado por:

$$c = \mu + \frac{\sigma}{\sqrt{n}} \phi^{-1}(p);$$
 - Dado que as **EMV**'s de μ e σ^2 são $\widehat{\mu} = \bar{X}$ e $\widehat{\sigma^2} = S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$, determine a **EMV** de c , chame ela de \widehat{c} .
 - Expresse \widehat{c} em termos de x_i se $n = 25$ e $p = .95$
- 6-
- Mostre que a $f(x; \theta) = \frac{\theta}{x^{\theta+1}}$, $x \geq 1, \theta \in \Theta = (0, \infty)$ é uma fdp. ;
 - Com base em uma amostra aleatória de tamanho n deste p.d.f., mostre que a estatística $\prod_{i=1}^n X_i$ é suficiente para θ , assim como a estatística $\sum_{i=1}^n \log(X_i)$

- 7- Se X é uma v.a. tendo fdp com dist. Geométrica $f(x; \theta) = \theta(1 - \theta)^{x-1}$, $x = 1, 2, \dots$, $\theta \in \Theta = (0, 1)$. Mostre que \bar{X} é uma estatística suficiente para θ .

1.5 Estimativas Imparciais de Variância Mínima Uniforme

Talvez o segundo método mais popular de estimar um parâmetro seja com base nos conceitos de imparcialidade e variância mínima. Este método será discutido aqui até certo ponto e também será ilustrado por exemplos.

Para iniciar, seja X_1, \dots, X_n seja uma amostra aleatória com fdp. $f(\cdot; \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$, e vamos introduzir a notação $U = U(X_1, \dots, X_n)$ para uma estimativa de θ .

Definição 5

Uma estimativa de U é dita **Imparcial** se $E_\theta U = \theta$ para todo $\theta \in \Theta$.

A seguir apresentamos alguns exemplos de estimativas imparciais.

Exemplo 20 Sejam X_1, \dots, X_n uma amostra aleatória tendo uma das seguintes distribuições:

- (i) $X_i \sim B(1, \theta)$, $\theta \in (0, 1)$, \bar{X} é uma estimativa imparcial para θ .
- (ii) $X_i \sim \mathcal{P}(\theta)$, $\theta > 0$ \bar{X} e $\text{Var}_\theta(X_1)$ são estimativas imparciais para θ .
- (iii) Se $X_i \sim \mathcal{N}(\theta, \sigma^2)$, com σ conhecido, novamente \bar{X} é uma estimativa imparcial para θ .
- (iv) Se $X_i \sim \mathcal{N}(\mu, \theta)$, com $\sigma > 0$, μ conhecido, então a variância amostral $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ é uma estimativa imparcial para θ .
- (v) Se $X_i \sim \Gamma(\theta, \beta)$, $\beta = 1$, \bar{X} é uma estimativa imparcial para θ .
- (vi) Se $X_i \sim \Gamma(\alpha, \theta)$, $\alpha = 1$, \bar{X} é uma estimativa imparcial para θ .

Solução

- (i) Se $X_i \sim B(1, \theta)$, $\theta \in (0, 1)$, $E[X_i] = \theta$ logo

$$E_\theta[\bar{X}] = E_\theta\left[\frac{\sum_{i=1}^n X_i}{n}\right] = \frac{\sum_{i=1}^n E[X_i]}{n} = \frac{n\theta}{n} = \theta.$$
 Portanto \bar{X} é uma estimativa imparcial para θ .
- (ii) Se $X_i \sim \mathcal{P}(\theta)$, $\theta > 0$ $E[X_i] = \theta$ logo

$$E_\theta[\bar{X}] = E_\theta\left[\frac{\sum_{i=1}^n X_i}{n}\right] = \frac{n\theta}{n} = \theta$$
 e $\text{Var}_\theta(X_1)$ são estimativas imparciais para θ .

(iii) Se $X_i \sim N(\theta, \sigma^2)$, com σ conhecido, novamente $E[X_i] = \theta$ logo
 $E_\theta[\bar{X}] = E_\theta\left[\frac{\sum_{i=1}^n X_i}{n}\right] = \frac{n\theta}{n} = \theta$. Portanto \bar{X} é uma estimativa imparcial para θ .

(iv) Se $X_i \sim N(\mu, \theta)$, com $\sigma > 0$, μ conhecido, então $\left(\frac{X_i - \mu}{\sqrt{\theta}}\right)^2 \sim \chi_1^2$ consequentemente $E_\theta\left[\left(\frac{X_i - \mu}{\sqrt{\theta}}\right)^2\right] = 1$ logo

$$E_\theta[S^2] = E_\theta\left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{n}\right] = \theta E_\theta\left[\frac{1}{n} \sum_{i=1}^n \left(\frac{X_i - \mu}{\sqrt{\theta}}\right)^2\right]$$

$$= \frac{\theta}{n} \sum_{i=1}^n E_\theta\left[\left(\frac{X_i - \mu}{\sqrt{\theta}}\right)^2\right] = \frac{\theta n}{n} = \theta.$$

Portanto S^2 é uma estimativa imparcial para θ .

(v) Se $X_i \sim \Gamma(\theta, \beta)$, $\beta = 1$, \bar{X} é uma estimativa imparcial para θ .

(vi) Se $X_i \sim \Gamma(\alpha, \theta)$, $\alpha = 1$, \bar{X} é uma estimativa imparcial para θ .

Definição 6 Uma estimativa **Imparcial** $U = U(X_1, \dots, X_n)$ de θ é dita **Imparcial de Variância Mínima Uniforme (EIVMU)**, se para qualquer outra estimativa **imparcial** $V = V(X_1, \dots, X_n)$ a seguinte desigualdade é válida:

$$\text{Var}_\theta(U) \leq \text{Var}_\theta(V) \text{ para todo } \theta \in \Theta.$$

Teorema 6 Desigualdade de Cramer-Rao seja X_1, \dots, X_n seja uma amostra aleatória com fdp. $f(\cdot; \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$ e suponha que certas condições de regularidade são conhecidas. Então, para qualquer estimativa **imparcial** $U = U(X_1, \dots, X_n)$ de θ a seguinte desigualdade é válida:

$$\text{Var}_\theta(U) \geq \frac{1}{nI(\theta)} \text{ para todo } \theta \in \Theta. \quad (1.1)$$

onde

$$I(\theta) = E_\theta\left[\frac{\partial \log(f(X; \theta))}{\partial \theta}\right]^2, \quad X \sim f(\cdot; \theta). \quad (1.2)$$

Observação 1 As condições não especificadas mencionadas na formulação do teorema inclui a suposição de que o domínio de x na f.d.p. $f(x; \theta)$ não depende de θ ; assim, a distribuição $U(0, \theta)$, por exemplo, é deixada de fora. Além disso, as condições incluem a validade de intercambiar as operações de diferenciação e integração em certas expressões.

A quantidade $I(\theta)$ é denominada *Informação de Fisher* fornecida pela amostra aleatória X_1, \dots, X_n sobre o parâmetro θ . Uma justificativa para a "informação" decorre do fato de que $\sigma_{\hat{\theta}}^2 = 1/I(\theta)$, de modo que quanto maior $I(\theta)$ menor é a variância $\sigma_{\hat{\theta}}^2$ e, portanto $\hat{\theta}$ é mais concentrado em torno de θ . O oposto acontece para pequenos valores de $I(\theta)$.

Observação 2 *Pode-se mostrar que, em condições adequadas, a quantidade $I(\theta)$ em (1.2) também pode ser calculado da seguinte forma:*

$$I(\theta) = -E_{\theta} \left[\frac{\partial^2 \log(f(X; \theta))}{\partial \theta^2} \right]. \quad (1.3)$$

Essa expressão geralmente é mais fácil de calcular. A desigualdade de Cramér-Rao é usada da seguinte maneira.

- (i) *Calcule as informação de Fisher por meio de (1.2) ou por meio de (1.3);*
- (ii) *Calcule o limite inferior de Cramér-Rao (C-R) apresentado em (8);*
- (iii) *Tente identificar uma estimativa imparcial cuja variância é igual ao C-R limite inferior de C-R(para todos $\theta \in \Theta$). Se tal estimativa for encontrada;*
- (iv) *Declare a estimativa descrita em (iii) como a estimativa UMVU de θ .*

O uso da desigualdade será ilustrado por dois exemplos; outros casos são deixados como exercícios.

Exemplo 21 *Sejam $X_1, \dots, X_n, \sim B(1, \theta)$ $f(x_i, \theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$, $x_i = 0$ ou 1 , $i = 1, \dots, n$, $\log(f(X, \theta)) = X \log(\theta) + (1 - X) \log(1 - \theta)$;*

$$1, \dots, n, \quad \frac{\partial \log(f(X; \theta))}{\partial \theta} = \frac{X}{\theta} - \frac{1 - X}{1 - \theta} \quad e \quad \frac{\partial^2 \log(f(X; \theta))}{\partial \theta^2} = -\frac{X}{\theta^2} - \frac{1 - X}{(1 - \theta)^2}$$

$$I(\theta) = -E_{\theta} \left[\frac{\partial^2 \log(f(X; \theta))}{\partial \theta^2} \right] = \frac{X}{\theta^2} + \frac{1 - X}{(1 - \theta)^2} = \frac{1}{\theta(1 - \theta)}$$

(ii) *O limite inferior de Cramér-Rao (C-R) é dado por $\frac{1}{nI(\theta)} = \frac{\theta(1-\theta)}{n}$;*

(iii) *Se $U = \bar{X}$ como $X \sim B(1, \theta)$ $E_{\theta}[\bar{X}] = \theta$, $\sigma^2[\bar{X}] = \frac{\sum_{i=1}^n \sigma^2[X_i]}{n^2} = \frac{n\theta(1-\theta)}{n^2} = \frac{1}{nI(\theta)}$*

(iv) *$U = \bar{X}$ é uma EIVMU de θ .*

Exemplo 22 Sejam X_1, \dots, X_n , v.a i.id $\sim P(\lambda)$, $\lambda > 0$ fazendo $\lambda = \theta$ temos:

$$f(x; \theta) = e^{-\theta} \frac{\theta^k}{k!}, k = 0, \dots, \log(f(x; \theta)) = -\theta + k \log(\theta) - \log(k!)$$

Então

$$\frac{\partial \log(f(X; \theta))}{\partial \theta} = -1 + \frac{k}{\theta} \quad e$$

$$\left[\frac{\partial \log(f(X; \theta))}{\partial \theta} \right]^2 = 1 + \frac{k^2}{\theta^2} - \frac{2k}{\theta}$$

$$\text{Como } E_\theta[X] = \theta \text{ e } E_\theta[X^2] = \theta(1 + \theta)$$

$$I(\theta) = E_\theta \left[\frac{\partial \log(f(X; \theta))}{\partial \theta} \right]^2 = E_\theta \left[1 + \frac{k^2}{\theta^2} - \frac{2k}{\theta} \right] = \frac{1}{\theta}$$

Como $\frac{1}{nI(\theta)} = \frac{\theta}{n}$ é o limite de Cramér-Rao, \bar{X} , é uma Estatística Suficiente para θ e $\text{Var}_\theta \bar{X} = \frac{\theta}{n}$, \bar{X} é a EIVMU de θ .

Exemplo 23 Se $X \sim \text{Exp}(1/\theta)$ isto é $f(X, \theta) = \frac{1}{\theta} e^{-\frac{X}{\theta}}$, então $E_\theta[X] = \theta$ e $\sigma^2[X] = \theta^2$;

$$\text{i } \log(f(X, \theta)) = -\log(\theta) - \frac{X}{\theta}$$

$$\frac{\partial \log(f(X; \theta))}{\partial \theta} = -\frac{1}{\theta} + \frac{X}{\theta^2}, \quad e \quad \frac{\partial^2 \log(f(X; \theta))}{\partial \theta^2} = \frac{1}{\theta^2} - \frac{2X}{\theta^3}$$

$$\begin{aligned} \text{ii } I(\theta) &= -E_\theta \left[\frac{\partial^2 \log(f(X; \theta))}{\partial \theta^2} \right] \\ &= E_\theta \left[\frac{1}{\theta^2} - \frac{2X}{\theta^3} \right] = -\frac{1}{\theta^2} + \frac{2}{\theta^2} = \frac{1}{\theta^2} \end{aligned}$$

iii A cota inferior C-R é dada por $\frac{1}{nI(\theta)} = \frac{\theta^2}{n}$

iv Considere $U = \bar{X} \sigma^2[U] = \frac{\theta^2}{n} = \frac{1}{nI(\theta)}$. Portanto \bar{X} é uma EIVMU de θ .

Existe uma maneira alternativa de procurar EIVMU, em particular, quando a abordagem por meio da desigualdade de Cramér-Rao deixa de produzir tal estimativa. Esta abordagem depende fortemente do conceito de suficiência já introduzido e também de um conceito técnico adicional, denominado completude.

Definição 7 (Completeness) *Seja T uma var. aleatória com fdp $f_T(\cdot; \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$, a família $\{f_T(\cdot; \theta), \theta \in \Theta\}$ ou a var. aleatória T é dita **completa** se para $h : \mathbb{R} \rightarrow \mathbb{R}$ tal que $E_\theta h(T) = 0$ para todo $\theta \in \Theta$ então $h(t) = 0$.*

Teorema 7 (*Rao-Blackwell, Lehmann-Scheffé*) *Se X_1, \dots, X_n é uma amostra aleatória com fdp $f(\cdot; \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$ e $T = T(X_1, \dots, X_n)$ é uma estatística suficiente para θ e completa. Se $U = U(X_1, \dots, X_n)$ é uma estatística imparcial de θ define a estatística*

$$\phi(T) = E_\theta(U|T)$$

Então

- i** *A var. aleat. $\phi(T)$ é função apenas da estatística suficiente T ;*
- ii** *$\phi(T)$ é uma estatística imparcial de θ ;*
- iii** *$\sigma_\theta^2[\phi(T)] < \sigma_\theta^2[U]$, $\theta \in \Theta$ provado que $E_\theta U^2 < \infty$*
- iv** *$\phi(T)$ é única EIVMU de θ .*

Os exemplos a seguir ilustram como aplicar o Teorema de **Rao-Blackwell, Lehmann-Scheffé** em casos concretos.

Exemplo 24 *Determine a EIVMU de θ com base na amostra aleatória X_1, \dots, X_n da distribuição $P(\theta)$.*

SOLUÇÃO: *Já vimos nos exemplos 16 e 20 que se $X \sim P(\theta)$, $T = X_1 + \dots + X_n$ e X_1 são estatística suficiente e imparcial de θ respectivamente. Vamos construir agora a distribuição condicional de X_1 dado $T = t$.*

$$\begin{aligned}
P(X_1 = x \mid T = t) &= P(X_1 = x \mid X_2 + \dots + X_n = t - x) \\
&= \frac{P(X_1 = x; X_2 + \dots + X_n = t - x)}{P(X_1 + \dots + X_n = t)} \\
&= \frac{P(X_1 = x; X_2 + \dots + X_n = t - x)}{\sum_{x=0}^t P(X_1 = x) P(X_2 + \dots + X_n = t - x)} \\
&= \frac{e^{-\theta} \theta^x}{x!} \times \frac{e^{-(n-1)\theta} ((n-1)\theta)^{t-x}}{(t-x)!} \\
&\quad \times \frac{t!}{t! \sum_{x=0}^t P(X_1 = x) P(X_2 + \dots + X_n = t - x)} \\
&= \frac{e^{-\theta} \theta^x}{x!} \times \frac{e^{-(n-1)\theta} ((n-1)\theta)^{t-x}}{(t-x)!} \\
&\quad \times \frac{t!}{e^{-\theta} e^{-(n-1)\theta} \sum_{x=0}^t t! \frac{\theta^x}{x!} \frac{((n-1)\theta)^{t-x}}{(t-x)!}} \\
&= \frac{t! \theta^x ((n-1)\theta)^{t-x}}{x! (t-x)! (n\theta)^t} = \frac{t!}{x! (t-x)!} \left(\frac{\theta}{n\theta}\right)^x \left(\frac{(n-1)\theta}{n\theta}\right)^{t-x} \\
&= \frac{t!}{x! (t-x)!} \left(\frac{1}{n}\right)^x \left(1 - \frac{1}{n}\right)^{t-x} \sim B\left(t, \frac{1}{n}\right)
\end{aligned}$$

Logo $E_\theta(X_1 = x \mid T = t) = \frac{t}{n}$ então a $\phi(T) = E_\theta(X_1 = x \mid T = t) = \frac{t}{n} = \bar{X}$ portanto \bar{X} é a EIVMU de θ .

Exemplo 25 Seja X_1, \dots, X_n é uma amostra aleatória da distribuição $N(\mu, \sigma^2)$. Suponha que σ^2 é conhecido e façamos $\mu = \theta$, então

$$f(x; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\theta)^2}{2\sigma^2}}, x \in \mathbb{R}$$

e portanto

$$\log(f(x; \theta)) = \log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{(x-\theta)^2}{2\sigma^2}.$$

Logo,

$$\begin{aligned}\frac{\partial \log (f(x; \theta))}{\partial \theta} &= \frac{1}{\sigma} \frac{x - \theta}{\sigma}, \\ \left[\frac{\partial \log (f(x; \theta))}{\partial \theta} \right]^2 &= \frac{1}{\sigma^2} \left(\frac{x - \theta}{\sigma} \right)^2, \\ I(\theta) = E_{\theta} \left[\frac{\partial \log (f(X; \theta))}{\partial \theta} \right]^2 &= \frac{1}{\sigma^2} E_{\theta} \left(\frac{X - \theta}{\sigma} \right)^2 = \frac{1}{\sigma^2}\end{aligned}$$

Pois $\left(\frac{X-\theta}{\sigma}\right)^2 \sim \chi_1^2$ logo $E_{\theta} \left(\frac{X-\theta}{\sigma}\right)^2 = 1$, consequentemente o limite inferior de Cramér-Rao é dado por $\frac{\sigma^2}{n}$. Calculando, $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$, como \bar{X} é uma estatística imparcial para θ pelo Teorema Cramér-Rao \bar{X} é uma EIVMU de θ quando σ é conhecido.

Suponha que μ é conhecido e façamos $\sigma^2 = \theta$, então

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-\frac{(x-\mu)^2}{2\theta}}, x \in \mathbb{R}$$

e portanto

$$\log (f(x; \theta)) = -\frac{1}{2} \log (2\pi) - \frac{1}{2} \log (\theta) - \frac{(x - \mu)^2}{2\theta}.$$

Logo,

$$\begin{aligned}\frac{\partial \log (f(x; \theta))}{\partial \theta} &= -\frac{1}{2\theta} + \frac{(x - \mu)^2}{2\theta^2}, \\ \left[\frac{\partial \log (f(x; \theta))}{\partial \theta} \right]^2 &= \frac{1}{4\theta^2} - 2\frac{1}{2\theta} \frac{(x - \mu)^2}{2\theta^2} + \left(\frac{(x - \mu)^2}{2\theta^2} \right)^2 \\ &= \frac{1}{4\theta^2} - \frac{1}{2\theta^2} \left(\frac{x - \mu}{\sqrt{\theta}} \right)^2 + \frac{1}{4\theta^2} \left(\frac{x - \mu}{\sqrt{\theta}} \right)^4 \\ I(\theta) = E_{\theta} \left[\frac{\partial \log (f(X; \theta))}{\partial \theta} \right]^2 &= E_{\theta} \left[\frac{1}{4\theta^2} - \frac{1}{2\theta^2} \left(\frac{x - \mu}{\sqrt{\theta}} \right)^2 + \frac{1}{4\theta^2} \left(\frac{x - \mu}{\sqrt{\theta}} \right)^4 \right] \\ &= \frac{1}{4\theta^2} - \frac{1}{2\theta^2} E_{\theta} \left(\frac{x - \mu}{\sqrt{\theta}} \right)^2 + \frac{1}{4\theta^2} E_{\theta} \left(\frac{x - \mu}{\sqrt{\theta}} \right)^4 \\ &= \frac{1}{4\theta^2} - \frac{1}{2\theta^2} + \frac{3}{4\theta^2} = \frac{1}{2\theta^2}\end{aligned}$$

Pois $E_{\theta} \left(\frac{x-\mu}{\sqrt{\theta}} \right)^2 = 1$ e $E_{\theta} \left(\frac{x-\mu}{\sqrt{\theta}} \right)^4 = 3$ devido ao fato que $Z = \frac{x-\mu}{\sqrt{\theta}} \sim \mathcal{N}(0, 1)$, $E[Z^{2n}] = \frac{(2n)!}{2^n(n!)}$. Como μ é conhecido vamos considerar agora a estatística:

$$W = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sqrt{\theta}} \right)^2, \quad W \sim \chi_n^2 \quad E[W] = n, \quad \text{Var}[W] = 2n$$

$$\text{Se } U = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2, \quad U = \frac{\theta}{n} W, \quad E[U] = \theta \quad \text{Var}[U] = \frac{\theta^2}{n^2} \text{Var}[W] = \frac{2\theta^2}{n}.$$

Observe que U é imparcial e $\text{Var}[U] = \frac{1}{nI(\theta)}$ portanto U é uma EIVMU de θ quando μ é conhecido.

Vejamos agora o caso onde μ e σ são desconhecidos. Fazendo $\mu = \theta_1$ e $\sigma^2 = \theta_2$. Suponha que estejamos interessados ??em encontrar um estimador EIVMU de θ_2 . Já vimos que (\bar{X}, S^2) são estatística suficientes e imparciais de μ, σ respectivamente. Calculando o limite de Cramér-Rao, considerando θ_1 constante temos:

$$\frac{1}{nI(\theta)} = \frac{2\theta_2^2}{n}$$

Calculando

$$\begin{aligned} \text{Var}_{\theta_2}(S^2) &= \text{Var}_{\theta_2} \left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right) \\ &= \frac{1}{(n-1)^2} \sum_{i=1}^n \text{Var} \left((X_i - \bar{X})^2 \right) \\ &= \frac{\theta_2}{(n-1)^2} \text{Var} \left(\sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sqrt{\theta_2}} \right)^2 \right) = \frac{2\theta_2^2(n-1)}{(n-1)^2} = \frac{2\theta_2^2}{(n-1)} > \frac{2\theta_2^2}{n} \end{aligned}$$

$$W = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sqrt{\theta_2}} \right)^2 \sim \chi_{n-1}^2 \quad \text{logo } \text{Var}(W) = 2(n-1)$$

Conclusão: S^2 é uma EIVMU no entanto a desigualdade de Cramér Rao não é satisfeita como igualdade.

1.6 Exercícios

Capítulo 2

Intervalos de Confiança e Regiões de Confiança

2.1 A Ideia Básica da Estimação Intervalar

Suponha que estejamos interessados em construir uma estimativa pontual da média μ em uma distribuição normal $N(\mu, \sigma^2)$ com variância conhecida; isso deve ser feito com base em uma amostra aleatória de tamanho n , X_1, \dots, X_n , extraído da subjacente distribuição. Isso equivale a construir uma estatística adequada dos X_i , chamada $V = V(X_1, \dots, X_n)$, que para os valores observados x_i de X_i , $i = 1, \dots, n$ é uma entidade numérica e declara-a como o valor (desconhecido) de μ . Isso parece um tanto presunçoso, uma vez que, a partir do conjunto de valores possíveis para μ , $-\infty < \mu < \infty$, apenas um é selecionado como seu valor. Pensando assim, pode ser mais razoável visar, em vez disso, um intervalo aleatório que conterá o valor (desconhecido) de μ com alta probabilidade (prescrita). Isso é exatamente o que um intervalo de confiança faz.

Para ser mais preciso, ao lançar o problema em um cenário geral, seja X_1, \dots, X_n uma amostra aleatória de uma f.d.p. $f(\cdot; \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$, $L = L(X_1, \dots, X_n)$ e $U = U(X_1, \dots, X_n)$ duas estatísticas de X_i , tais que $L < U$. Então o intervalo com limites L e U , $[L, U]$, é chamado de um intervalo aleatório. Seja α um pequeno número em $(0, 1)$, como 0,005, 0,01, 0,05, e suponha que o intervalo aleatório $[L, U]$ contém θ com probabilidade igual para $1 - \alpha$ (como 0,995, 0,99, 0,95), independentemente do valor verdadeiro de θ . Em outras palavras, suponha que:

$$P_\theta(L \leq \theta \leq U) = 1 - \alpha \text{ para todo } \theta \in \Theta. \quad (1)$$

Se a relação (1) for mantida, então dizemos que o intervalo aleatório $[L, U]$, é um intervalo de confiança para θ com nível de confiança $1 - \alpha$.

A interpretação da significância de um intervalo de confiança é baseada na interpretação da frequência relativa do conceito de probabilidade, da seguinte forma: Suponha que n v.a.'s independentes sejam extraídos de uma f.d.p. $f(\cdot; \theta)$, e x_1, \dots, x_n sejam seus valores observados. Além disso, seja $[L_1, U_1]$ o intervalo resultante a partir dos valores observados de $L = L(X_1, \dots, X_n)$ e $U = U(X_1, \dots, X_n)$; isto é, $L_1 = L(x_1, \dots, x_n)$ e $U_1 = U(x_1, \dots, x_n)$. Prossiga para construir de forma independente um segundo conjunto de r.v.a.'s como acima, e seja $[L_2, U_2]$ o intervalo resultante. Repita este processo independentemente um grande número de vezes, N , digamos, com o intervalo correspondente sendo $[L_N, U_N]$. Então, a interpretação de (1) é que, em média, cerca de $100(1 - \alpha)\%$ dos N intervalos acima irão, na verdade, contém o valor verdadeiro de θ . Por exemplo, para $\alpha = 0,05$ e $N = 1.000$, a proporção de tais intervalos será de 95%; ou seja, seria de esperar 950 de dos 1.000 intervalos construídos como acima para conter o valor verdadeiro de θ . A evidência empírica mostra que tal expectativa é válida.

Também podemos definir um limite de confiança superior para θ , $U = U(X_1, \dots, X_n)$, e um limite de confiança inferior para θ , $L = L(X_1, \dots, X_n)$, ambos com nível de confiança $1 - \alpha$, se, respectivamente, os intervalos $(-\infty, U]$ e $[L, \infty)$ são intervalos de confiança para θ com nível de confiança $1 - \alpha$. Quer dizer:

$$P_\theta(-\infty < \theta \leq U) = 1 - \alpha, \quad P_\theta(L \leq \theta < \infty) = 1 - \alpha \text{ para todo } \theta \in \Theta. \quad (2)$$

Existem algumas variações de (1) e (2). Por exemplo, quando a f.d.p. em questão é discreta, então igualdades em (1) e (2) raramente são obtidas para dados α e devem ser substituídos por desigualdades \geq . Além disso, exceto em casos especiais, igualdades em (1) e (2) são válidos apenas aproximadamente para grandes valores do tamanho da amostra n (mesmo nos casos em que os r.v. subjacentes são contínuos). Nesses casos, dizemos que os respectivos intervalos de confiança (limites de confiança) têm coeficiente de confiança aproximadamente $1 - \alpha$.

Finalmente, os parâmetros de interesse podem ser dois (ou mais) em vez de um, como presumimos até agora. Nesses casos, o conceito de intervalo de confiança é substituído por aquele de uma região de confiança (no parâmetros num espaço multidimensional). Este conceito será ilustrado por um exemplo ao estudarmos testes de hipótese, quando também expandiremos consideravelmente o que foi brevemente discutido aqui.

2.2 Intervalos de Confiança

Vamos formalizar na forma de uma definição alguns conceitos já introduzidos na seção anterior.

Definição 8 Se X_1, \dots, X_n é uma amostra aleatória com f.d.p. $f(\cdot; \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$. Então:

- (i) Um **intervalo aleatório** é um intervalo cujos limites são variáveis aleatórias.
- (ii) Um **intervalo de confiança** para θ com **nível de confiança** $1 - \alpha$ ($0 < \alpha < 1$, α pequeno, é um intervalo aleatório cujos limites são estatísticas, digamos $L(X_1, \dots, X_n)$ e $U(X_1, \dots, X_n)$ tais que: $L(X_1, \dots, X_n) < U(X_1, \dots, X_n)$ e

$$P_\theta(L(X_1, \dots, X_n) \leq \theta \leq U(X_1, \dots, X_n)) \geq 1 - \alpha \text{ para todo } \theta \in \Theta$$

- (iii) A estatística $L(X_1, \dots, X_n)$ é dita **limite inferior de confiança** para θ com nível de confiança $1 - \alpha$, se o intervalo $[L(X_1, \dots, X_n), \infty)$ é um intervalo de confiança para θ com nível de confiança $1 - \alpha$. Da mesma forma $U(X_1, \dots, X_n)$ é dita **limite superior de confiança** para θ com nível de confiança $1 - \alpha$, se o intervalo $(-\infty, U(X_1, \dots, X_n)]$ é um intervalo de confiança para θ com nível de confiança $1 - \alpha$.

Observação 3 A significância de um intervalo de confiança provém da interpretação da frequência relativa da probabilidade. Assim, com base nos valores observados x_1, \dots, x_n de X_1, \dots, X_n , constrói-se um intervalo com limites $L(X_1, \dots, X_n)$ e $U(X_1, \dots, X_n)$, e denota-se por $[L_1, U_1]$. Repete-se este experimento aleatório independentemente mais n vezes e da mesma forma, formando intervalo $[L_2, U_2]$. Repetindo-se este processo um grande número de vezes N independentemente cada vez, seja $[L_N, U_N]$ o intervalo correspondente. Então o fato de que $[L(X_1, \dots, X_n), U(X_1, \dots, X_n)]$ é um intervalo de confiança para θ com nível confiança $1 - \alpha$ significa que aproximadamente $100(1 - \alpha)\%$ dos N intervalos acima conterão θ , não importa qual seja seu valor.

Observação 4 Se $L(X_1, \dots, X_n)$ é um limite inferior e $U(X_1, \dots, X_n)$ é um limite superior de um intervalo de confiança para θ com nível de confiança $1 - \frac{\alpha}{2}$ então $[L(X_1, \dots, X_n), U(X_1, \dots, X_n)]$ é um intervalo de confiança para θ com nível de confiança $1 - \alpha$.

Esta seção é concluída com a construção de intervalos de confiança em alguns exemplos concretos. Ao fazer isso, nos baseamos fortemente na teoria da distribuição e estimativas pontuais. Seria, talvez, útil delinear as etapas que geralmente segue na construção de um intervalo de confiança.

1. Encontre uma v.a. que contém o parâmetro θ , as v.a.s $U(X_1, \dots, X_n)$, de preferência na forma de uma estatística suficiente, e cuja distribuição é (exatamente ou pelo menos aproximadamente) conhecido.

2. Determine os pontos adequados $a < b$ de modo que a v.a. na etapa (a) encontre-se em $[a, b]$ com P_θ -probabilidade $\geq 1 - \alpha$.
3. Na expressão da etapa (b), reorganize os termos para chegar a um intervalo cujos limites são estatísticas e contendo θ .
4. O intervalo na etapa (c) é o intervalo de confiança necessário.

2.3 Alguns exemplos de Intervalos de Confiança

Vejamos agora alguns exemplos de Intervalo de confiança.

Exemplo 26 Sejam $U(X_1, \dots, X_n)$ var. aleat. iid com distribuição $N(\mu, \sigma^2)$. Inicialmente considere σ conhecido nesse caso μ será o parâmetro e vamos considerar a seguinte estatística $T_n(\mu) = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$, T_n depende das v.a's X_i através da estatística suficiente \bar{X} e de μ , além disso $T_n \sim N(0, 1)$ para todo $\mu \in \mathbb{R}$.

A seguir vamos determinar $a < b$ tais que

$$P[a \leq N(0, 1) \leq b] = 1 - \alpha, \quad (3) \text{ como } T_n \sim N(0, 1)$$

$$P\left[a \leq \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \leq b\right] = 1 - \alpha$$

que é equivalente a

$$P\left[\bar{X} - b \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} - a \frac{\sigma}{\sqrt{n}}\right] = 1 - \alpha$$

Portanto

$$\left[\bar{X} - b \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} - a \frac{\sigma}{\sqrt{n}}\right] \quad (4)$$

É um intervalo de confiança para μ com nível de confiança $1 - \alpha$, comprimento $(b - a) \frac{\sigma}{\sqrt{n}}$. Agora vamos determinar a e b de forma que entre todos os intervalos de confiança com nível de confiança $1 - \alpha$ que são da forma (4), o mais curto é aquele para o qual $b - a$ é o menor possível, onde a e b satisfazem (3). Isso acontece se $b = c(> 0)$ e $a = -c$, onde c é o quantil $\alpha/2$ superior da distribuição $N(0, 1)$ que denotamos por $z_{\alpha/2}$. Portanto o menor intervalo de confiança para μ com nível de confiança $1 - \alpha$ (e que tem a forma (4)) é dado por

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Em seguida, suponha que μ seja conhecido, de modo que σ^2 é o parâmetro, nesse caso considere a seguinte v.a.:

$$\bar{T}_n(\sigma^2) = \frac{nS_n^2}{\sigma^2} \text{ onde } S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

$$\bar{T}_n(\sigma^2) = \frac{n}{\sigma^2} \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi_n^2$$

Agora vamos determinar dois números a e b tais que:

$$\text{Prob}\left(\left[a \leq \chi_n^2 \leq b\right]\right) = 1 - \alpha$$

$$\text{Prob}\left(\left[a \leq \frac{nS_n^2}{\sigma^2} \leq b\right]\right) = 1 - \alpha$$

$$\text{Prob}\left(\left[\frac{1}{b} \leq \frac{\sigma^2}{nS_n^2} \leq \frac{1}{a}\right]\right) = 1 - \alpha$$

$$\text{Prob}\left(\left[\frac{nS_n^2}{b} \leq \sigma^2 \leq \frac{nS_n^2}{a}\right]\right) = 1 - \alpha$$

O intervalo de confiança é dado por:

$$\left[\frac{nS_n^2}{b} \leq \sigma^2 \leq \frac{nS_n^2}{a} \right]$$

Agora utilizando a tabela da distribuição χ_n^2 encontramos $\chi_{n;1-\alpha/2}^2$ e $\chi_{n;\alpha/2}^2$ tais que $\text{Prob}(X \leq \chi_{n;1-\alpha/2}^2) = \text{Prob}(X \geq \chi_{n;\alpha/2}^2) = \alpha/2$ e temos o seguinte intervalo:

$$\left[\frac{nS_n^2}{\chi_{n;\alpha/2}^2} \leq \sigma^2 \leq \frac{nS_n^2}{\chi_{n;1-\alpha/2}^2} \right],$$

Se $n = 25$, $\sigma = 1$ e $1 - \alpha = 0,95$ então $z_{\frac{\alpha}{2}} = 1,96$, $\chi_{n;1-\alpha/2}^2 = 40,646$, $\chi_{n;\alpha/2}^2 = 13,120$ nesse caso o Intervalo de confiança para a média é dado por:

$$IC_{\mu;1-\alpha} = \left[\bar{X} - 1,96 \frac{1}{\sqrt{25}}, \bar{X} + 1,96 \frac{1}{\sqrt{25}} \right]$$

O Intervalo de Confiança para σ^2 é dado por:

$$IC_{\sigma^2;1-\alpha} = \left[\frac{25S_n^2}{40,646} \leq \sigma^2 \leq \frac{25S_n^2}{13,120} \right],$$

2.4 Intervalos de Confiança na Presença de Parâmetros Incômodos